Rapport de Mini-Projet
Prévision du Risque de Sécheresse

Réalisé par **Wissem Bahrouni**

1 Introduction

Ce mini-projet porte sur la prévision du risque de sécheresse à partir de données environnementales et climatiques. L'objectif est de prédire un indice de sécheresse (SPI – Standardized Precipitation Index) à l'aide de plusieurs approches, en progressant des modèles basiques vers une modélisation séquentielle par réseau LSTM.

2 Préparation des données

Le fichier source est `ex16_secheresse_spi.csv`. Les colonnes sont détectées de façon défensive afin de gérer les variantes possibles. Après nettoyage (suppression des lignes avec valeurs manquantes dans la cible principale), le jeu de données est divisé en un ensemble d'entraînement (80 %) et un ensemble de test (20 %).

Variables tabulaires (features) Les variables numériques retenues excluent : les identifiants, les dates, les textes, les colonnes de lag, les colonnes LSTM, et les colonnes géographiques. Elles couvrent des indicateurs climatiques et environnementaux (précipitations, température, humidité, etc.).

Variables temporelles (lag) Des colonnes de type *lag* ou contenant les mots-clés `observed`, `spi`, `index` sont détectées automatiquement pour alimenter le modèle LSTM.

Cibles Deux cibles sont utilisées :

- `target_stage1_tabular_score` : score de risque tabulaire (parties A à C) ;
- `lstm_drought_next_3m` : risque de sécheresse à 3 mois (partie D – LSTM). Si cette colonne est absente, elle est construite par décalage temporel de 3 unités de la cible principale.

Colonnes géographiques Les colonnes `latitude`, `longitude`, `utm32_easting` et `utm32_northing` sont conservées pour la cartographie finale.

3 Modèle basique – Random Forest et XGBoost

Deux modèles ensemblistes sont entraînés avec 200 estimateurs :

- **Random Forest** (`n_estimators=200`, `random_state=42`) ;
- **XGBoost** (`n_estimators=200`, `learning_rate=0.1`, `max_depth=5`).

Les métriques d'évaluation utilisées sont définies comme suit :

Modèle	MAE	RMSE	R^2
RF Basique	8.791	10.998	0.8177
XGBoost Basique	9.168	11.418	0.8035

Table 1 – Performances des modèles basiques

Ces deux modèles constituent la référence. Un graphique d'importance des variables (barres horizontales) est produit pour le Random Forest. Selon l'interprétation du notebook, les résultats tabulaires se situent autour de $R^2 \approx 0{,}80$–$0{,}82$.

4 Amélioration légère – Clustering KMeans

Pour enrichir les variables tabulaires, un clustering KMeans est appliqué sur les données standardisées. Le nombre optimal de clusters est déterminé par la **méthode du coude** (courbe d'inertie en fonction de k), en testant $k \in \{2, \ldots, 9\}$.

Le nombre retenu est $k = 4$. Une variable `cluster` est ajoutée aux features, puis Random Forest et XGBoost sont ré-entraînés.

Modèle	MAE	RMSE	R^2
RF Basique	8.791	10.998	0.8177
XGBoost Basique	9.168	11.418	0.8035
RF + KMeans	8.790	10.980	0.8183
XGBoost + KMeans	9.098	11.353	0.8057

Table 2 – Comparaison avant et après KMeans

L'ajout de la variable cluster améliore très légèrement les performances. Le Random Forest passe de $R^2 = 0.8177$ à $R^2 = 0.8183$, tandis que XGBoost passe de $R^2 = 0.8035$ à $R^2 = 0.8057$. L'amélioration reste donc marginale, mais elle montre que les clusters apportent une petite information supplémentaire sur la structure climatique ou environnementale des observations.

5 Réseau de neurones – MLP (Perceptron Multicouche)

Un réseau MLP est construit avec Keras / TensorFlow. La fonction `build_mlp` permet de configurer le nombre de couches, le nombre de neurones, le dropout et le taux d'apprentissage.

MLP non tuné Configuration initiale : 2 couches, 64 neurones, dropout = 0,2, lr = 10^{-3}, 50 époques. Une courbe de perte (MSE) est tracée pour la validation et l'entraînement.

Tuning manuel Une grille de 4 configurations est explorée :

Couches	Neurones	Dropout	lr	Batch	Époques
2	64	0,2	10^{-3}	32	80
3	128	0,3	5×10^{-4}	64	100
2	128	0,1	10^{-3}	16	80
3	64	0,3	10^{-3}	32	100

Table 3 – Grille de configurations MLP testées

Modèle	MAE	RMSE	R^2
MLP non tuné	9.064	11.407	0.8039
MLP Tuné	8.793	11.113	0.8139

TABLE 4 – Comparaison MLP non tuné vs. tuné

Le MLP tuné améliore légèrement les performances par rapport au MLP non tuné : le $\mathbf{R^2}$ passe de 0.8039 à 0.8139. Cette amélioration montre que le choix des hyperparamètres influence la qualité du réseau. Cependant, le MLP tuné reste légèrement inférieur au Random Forest avec KMeans, qui obtient $\mathbf{R^2}$ = 0.8183.

6 Modèle avancé – LSTM (Long Short-Term Memory)

6.1 Justification

Le risque de sécheresse est un phénomène **temporel** : il dépend de l'historique des précipitations, de l'humidité et de l'indice SPI sur les mois précédents. Un réseau LSTM est donc plus adapté qu'un MLP classique, car il modélise explicitement les dépendances temporelles dans des séquences glissantes.

6.2 Construction des séquences

Les colonnes temporelles détectées (contenant les mots-clés `observed`, `spi`, `index`, `lag`, `month`, `humidity`, `rainfall`, `temperature`) sont utilisées comme entrées. Une fenêtre glissante de taille W est appliquée pour construire des séquences d'entraînement :

$$\mathbf{x}_t = (x_{t-W+1},\, x_{t-W+2},\, \ldots,\, x_t) \;\longrightarrow\; y_{t+1}$$

La cible est la valeur de risque de sécheresse sur les 3 prochains mois (`lstm_drought_next_3m`).

6.3 LSTM non tuné

Configuration de départ : 1 couche LSTM, 32 unités, dropout = 0,2, lr = 10^{-3}, fenêtre $W = 12$, 30 époques.

6.4 Tuning du LSTM

Une grille de 5 configurations est testée en faisant varier la taille de fenêtre, le nombre de couches, le nombre d'unités et les hyperparamètres d'entraînement :

W	Couches	Unités	Dropout	lr	Batch	Époques
12	1	32	0,2	10^{-3}	32	50
12	2	64	0,2	5×10^{-4}	16	80
24	1	64	0,3	10^{-3}	32	60
24	2	128	0,3	10^{-4}	64	100
6	2	32	0,1	10^{-3}	16	60

TABLE 5 – Grille de configurations LSTM testées

Modèle	MAE	RMSE	R^2
LSTM non tuné	20.769	24.515	-0.1398
LSTM Tuné	4.363	5.423	0.9442

Table 6 – Résultats du LSTM

Le LSTM tuné obtient le meilleur score avec $R^2 = 0.9442$. Cette performance s'explique par le changement de cible et de variables : le modèle prédit lstm_drought_next_3m à partir de séquences temporelles, ce qui correspond mieux à la dynamique de la sécheresse. La comparaison avec les modèles tabulaires doit donc être interprétée avec prudence, car le LSTM ne résout pas exactement le même problème que les parties A à C.

7 Discussion comparative

Partie	Modèle	MAE	RMSE	R^2
A	RF Basique	8.791	10.998	0.8177
A	XGBoost Basique	9.168	11.418	0.8035
B	RF + KMeans	8.790	10.980	0.8183
B	XGBoost + KMeans	9.098	11.353	0.8057
C	MLP non tuné	9.064	11.407	0.8039
C	MLP Tuné	8.793	11.113	0.8139
D	LSTM non tuné	20.769	24.515	-0.1398
D	LSTM Tuné	4.363	5.423	0.9442

Table 7 – Tableau comparatif de tous les modèles.

Analyse

- Les modèles Random Forest et XGBoost donnent de bons résultats sur les variables tabulaires, avec un R^2 autour de 0.80 à 0.82.
- L'ajout de KMeans apporte une amélioration très légère. L'effet est positif mais marginal.
- Le MLP tuné améliore le MLP non tuné, mais il ne dépasse pas le Random Forest avec KMeans.
- Le LSTM non tuné donne un R^2 négatif, ce qui signifie qu'il fait pire qu'une prédiction moyenne.
- Le LSTM tuné obtient le meilleur score avec $R^2 = 0.9442$, car il exploite les séquences temporelles adaptées à la prévision du risque de sécheresse à 3 mois.
- Cette comparaison doit être nuancée, car le LSTM utilise une nouvelle cible et des variables temporelles différentes des modèles tabulaires.

8 Cartographie – Projection UTM 32N (EPSG :32632)

Une carte double est produite pour visualiser les prédictions du risque de sécheresse sur le territoire tunisien :

1. La carte est produite avec les prédictions du Random Forest basique, utilisé ici comme modèle tabulaire de référence facilement associable aux coordonnées géographiques de chaque observation. Le meilleur modèle global reste le LSTM tuné, mais ses prédictions sont construites à partir de séquences temporelles, ce qui rend leur cartographie directe moins simple.
2. Vérification de la cohérence des coordonnées UTM 32N par recalcul via `pyproj` (EPSG :4326 → EPSG :32632).
3. Création de deux `GeoDataFrame` : un en WGS84 (EPSG :4326) et un en UTM zone 32N (EPSG :32632).
4. Chargement du contour de la Tunisie depuis Natural Earth et reprojection en EPSG :32632.

5. Filtrage spatial : filtrage par boîte englobante (latitude $\in [29, 38]$, longitude $\in [7, 12]$) puis filtrage géométrique avec une tolérance de 5 km.
6. Affichage côte à côte des deux cartes avec colormap `RdYlGn`.

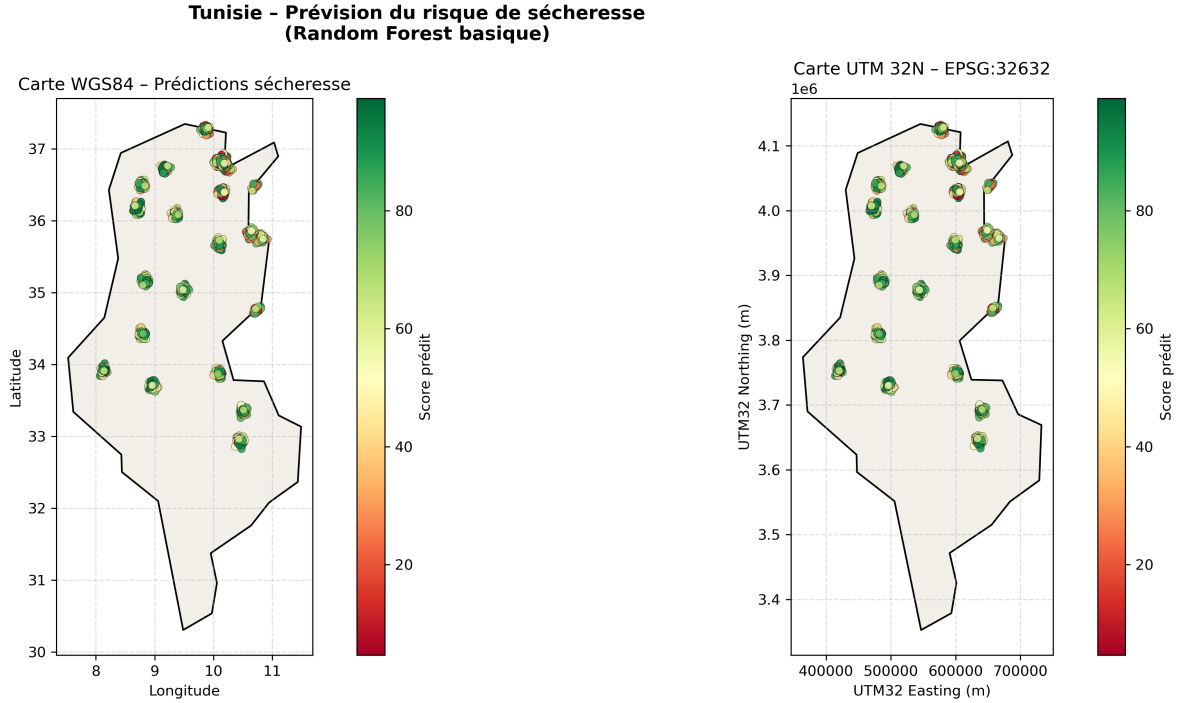


FIGURE 1 – Prévision du risque de sécheresse en Tunisie – Gauche : WGS84 (EPSG :4326) / Droite : UTM 32N (EPSG :32632)

La carte de droite (UTM 32N) est la projection de référence pour les analyses spatiales sur la Tunisie, car elle conserve les distances métriques avec une déformation minimale.

9 Conclusion

Ce mini-projet a permis de comparer plusieurs approches pour la prévision du risque de sécheresse :

— Les modèles Random Forest et XGBoost donnent de bonnes performances de base sur les variables tabulaires, avec un R^2 proche de 0.80. L'ajout de KMeans améliore légèrement les résultats, mais l'effet reste marginal.

— Le MLP tuné améliore le MLP non tuné, mais il reste légèrement inférieur au Random Forest avec KMeans. Le résultat le plus important concerne le LSTM tuné, qui atteint $R^2 = 0.9442$. Cette performance s'explique par l'utilisation de séquences temporelles adaptées à la prévision du risque de sécheresse à 3 mois.

— Il faut toutefois noter que le LSTM utilise une nouvelle cible et des variables temporelles différentes. Il est donc le meilleur modèle pour la modélisation séquentielle, tandis que Random Forest reste une très bonne référence pour la modélisation tabulaire.

Le LSTM tuné est donc le modèle recommandé pour ce type de problème. Le tuning est indispensable : sans lui, le LSTM est moins performant qu'une prédiction par la moyenne. La qualité de la modélisation dépend fortement de la disponibilité de séries temporelles suffisamment longues et cohérentes.