Rapport de Mini-Projet
Analyse de la Satisfaction Hôtelière

Réalisé par **Wissem Bahrouni**

1 Introduction

Ce mini-projet porte sur la modélisation de la satisfaction hôtelière à partir de données tabulaires et textuelles. L'objectif est de prédire un score de satisfaction à l'aide de plusieurs approches, en progressant du modèle basique vers l'analyse textuelle avancée.

2 Préparation des données

Le fichier source est `ex06_avis_hoteliers.csv`. Après chargement et nettoyage (suppression des lignes avec valeurs manquantes dans les colonnes cibles et les variables d'entrée), le jeu de données est divisé en un ensemble d'entraînement (80 %) et un ensemble de test (20 %).

Variables tabulaires (features) Les dix variables numériques suivantes sont utilisées comme entrées pour les modèles tabulaires :

Variable	Description
`population_density`	Densité de population
`urban_index`	Indice d'urbanisation
`temperature_c`	Température en degrés Celsius
`rainfall_mm`	Précipitations en mm
`humidity_pct`	Taux d'humidité (%)
`accessibility_score`	Score d'accessibilité
`service_load_score`	Charge de service
`economic_pressure_score`	Pression économique
`year`	Année
`month`	Mois

Cibles Deux cibles sont utilisées selon la partie du projet :
- `target_stage1_tabular_score` : score tabulaire de satisfaction (parties A à C) ;
- `text_hotel_score` : score issu de l'analyse textuelle (partie D).

Variables textuelles La colonne `text_fr` contient les avis hôteliers en français, utilisée dans la partie D. Les colonnes `latitude`, `longitude`, `utm32_easting` et `utm32_northing` sont conservées pour la cartographie.

3 Modèle basique – Random Forest et XGBoost

Deux modèles ensemblistes sont entraînés avec 200 estimateurs comme référence :

— **Random Forest** (`n_estimators=200`, `random_state=42`) ;
— **XGBoost** (`n_estimators=200`, `learning_rate=0.1`, `max_depth=5`).

Les métriques utilisées sont définies comme suit :

Modèle	**MAE**	**RMSE**	R^2
RF Basique	12.089	14.859	0.2586
XGBoost Basique	12.529	15.447	0.1987

TABLE 1 – Performances des modèles basiques

Les performances des modèles basiques restent limitées. Le Random Forest obtient un R^2 de 0.2586, ce qui signifie qu'il explique environ 26 % de la variance de la cible tabulaire. XGBoost obtient un score plus faible avec un R^2 de 0.1987. Ainsi, les variables tabulaires permettent une première prédiction, mais elles ne suffisent pas à expliquer fortement la satisfaction hôtelière.

4 Amélioration légère – ACP (Analyse en Composantes Principales)

Pour améliorer les modèles basiques, une ACP est appliquée après standardisation des variables. Le nombre de composantes retenues est déterminé automatiquement en fixant un seuil de variance expliquée à **90 %**.

$$\text{Variance expliquée cumulée} \geq 0{,}90$$

Le Random Forest et XGBoost sont ensuite ré-entraînés sur les composantes principales. Un graphique de variance cumulée par composante est tracé pour visualiser l'apport de chaque composante.

Modèle	**MAE**	**RMSE**	R^2
RF Basique	12.089	14.859	0.2586
XGBoost Basique	12.529	15.447	0.1987
RF + ACP	12.926	15.926	0.1482
XGBoost + ACP	13.666	17.028	0.0263

TABLE 2 – Comparaison avant et après ACP

Dans ce projet, l'ACP n'améliore pas les performances. Au contraire, le R^2 du Random Forest diminue de 0.2586 à 0.1482, et celui de XGBoost diminue de 0.1987 à 0.0263. Cela montre que la réduction de dimension a probablement supprimé une partie de l'information utile pour la prédiction. Les modèles à base d'arbres exploitent mieux les variables originales que les composantes principales.

5 Réseau de neurones – MLP (Perceptron Multicouche)

Un réseau de neurones de type MLP est construit avec Keras / TensorFlow. La fonction `build_mlp` permet de paramétrer :
— le nombre de couches cachées (`n_layers`) ;
— le nombre de neurones par couche (`n_units`) ;
— le taux de dropout (`dropout`) ;
— le taux d'apprentissage (`lr`) ;
— la taille du mini-lot (`batch`).

MLP non tuné La configuration de départ est : 2 couches, 64 neurones, dropout = 0,2, lr = 10^{-3}, 50 époques.

Tuning manuel Une grille de 4 configurations est testée :

Couches	Neurones	Dropout	lr	Batch	Époques
2	64	0,2	10^{-3}	32	80
3	128	0,3	5×10^{-4}	64	100
2	128	0,1	10^{-3}	16	80
3	64	0,3	10^{-3}	32	100

TABLE 3 – Grille de configurations MLP testées

La meilleure configuration est sélectionnée selon le R^2 sur le jeu de test.

Modèle	MAE	RMSE	R^2
MLP non tuné	11.687	14.412	0.3025
MLP Tuné	11.490	14.167	0.3259

TABLE 4 – Comparaison MLP non tuné vs. tuné

Le MLP tuné améliore légèrement les performances par rapport au MLP non tuné. Le R^2 passe de 0.3025 à 0.3259, avec une baisse de la MAE et de la RMSE. Cette amélioration montre que le choix des hyperparamètres influence la qualité du réseau. Cependant, l'amélioration reste modérée : le MLP tuné reste meilleur que les modèles tabulaires basiques, mais son score reste loin du modèle textuel.

6 Deuxième modélisation – Analyse textuelle (TF-IDF + Ridge)

Cette partie change à la fois la cible et les variables d'entrée. Au lieu du score tabulaire, on cherche à prédire `text_hotel_score` à partir des avis textuels en français (`text_fr`).

Justification Le score textuel est directement lié au ressenti exprimé dans l'avis ; il est mieux capturé par une représentation sémantique que par des variables environnementales.

Modèle TF-IDF + Ridge Un pipeline scikit-learn est construit :

1. Vectorisation TF-IDF : `max_features=5000`, bigrammes (`ngram_range=(1,2)`), normalisation sous-linéaire (`sublinear_tf=True`) ;
2. Régression Ridge (`alpha=1.0`).

Ce modèle constitue une approximation du modèle CamemBERT fine-tuné, qui n'est pas disponible sans GPU. Les hyperparamètres de CamemBERT envisagés sont : lr = 2×10^{-5}, batch = 16, max_len = 128, 3 époques, dropout = 0,1.

Tuning du paramètre alpha Plusieurs valeurs de α sont testées : {0,01 ; 0,1 ; 1,0 ; 10,0 ; 100,0}.

Modèle	MAE	RMSE	R^2
TF-IDF + Ridge (non tuné)	5.911	7.348	0.8350
TF-IDF + Ridge Tuné	5.911	7.348	0.8350

TABLE 5 – Résultats de la modélisation textuelle

Le modèle TF-IDF + Ridge obtient un R^2 de 0.8350, ce qui est nettement supérieur aux modèles tabulaires. Cela s'explique par le changement de cible : text_hotel_score est directement lié au contenu des

avis textuels. Le tuning de Ridge ne modifie pas les performances dans ce cas, car le meilleur alpha testé donne les mêmes métriques que le modèle initial.

7 Discussion comparative

Le tableau ci-dessous résume l'ensemble des modèles testés sur les deux cibles.

Partie	**Modèle**	**MAE**	**RMSE**	R^2
A	RF Basique	12.089	14.859	0.2586
A	XGBoost Basique	12.529	15.447	0.1987
B	RF + ACP	12.926	15.926	0.1482
B	XGBoost + ACP	13.666	17.028	0.0263
C	MLP non tuné	11.687	14.412	0.3025
C	MLP Tuné	11.490	14.167	0.3259
D	TF-IDF + Ridge	5.911	7.348	0.8350
D	TF-IDF + Ridge Tuné	5.911	7.348	0.8350

TABLE 6 – Tableau comparatif de tous les modèles

Analyse

- Les modèles tabulaires basiques donnent des performances limitées : le meilleur modèle de cette catégorie est Random Forest avec un R^2 de 0.2586.
- L'ACP ne permet pas d'améliorer les résultats. Elle dégrade même les performances des deux modèles, ce qui montre que les composantes principales conservent moins bien l'information utile que les variables originales.
- Le MLP tuné est le meilleur modèle tabulaire avec un R^2 de 0.3259. Le tuning améliore légèrement le réseau, mais les performances restent modérées.
- Le modèle textuel TF-IDF + Ridge est le meilleur modèle global avec un R^2 de 0.8350. Cette forte amélioration vient surtout du changement de cible et de variables : la cible text_hotel_score est directement liée au contenu des avis clients.
- Le tuning du modèle Ridge n'apporte pas d'amélioration mesurable, puisque les métriques restent identiques avant et après tuning.

8 Cartographie – Projection UTM 32N (EPSG :32632)

Une carte de prédictions de satisfaction hôtelière est produite sur le territoire tunisien. Les étapes sont les suivantes :

1. La carte est produite à partir des prédictions du Random Forest tabulaire, afin d'associer directement un score prédit aux coordonnées géographiques des observations.
2. Nettoyage et conversion des coordonnées géographiques (`latitude`, `longitude`).
3. Vérification de la cohérence des coordonnées UTM 32N (`utm32_easting`, `utm32_northing`) par rapport à la transformation calculée via `pyproj` (`EPSG:4326` → `EPSG:32632`).
4. Création d'un `GeoDataFrame` en projection UTM zone 32N.
5. Chargement du contour de la Tunisie et reprojection en EPSG :32632.

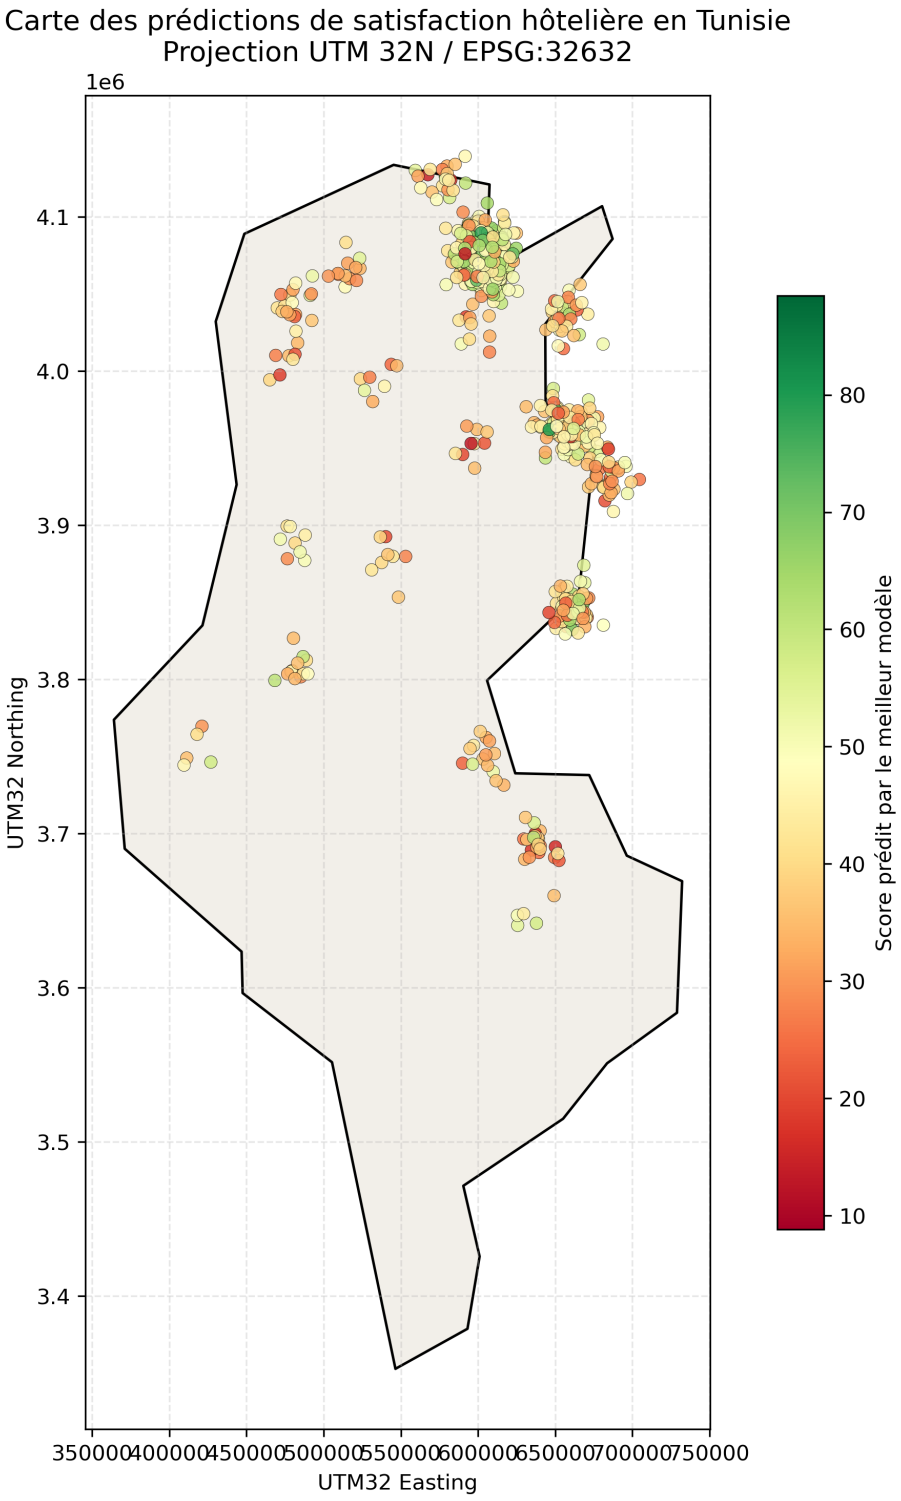


FIGURE 1 – Carte des prédictions de satisfaction hôtelière en Tunisie – Projection UTM 32N / EPSG :32632

La projection UTM zone 32N (EPSG :32632) est adaptée à la Tunisie car elle minimise les déformations métriques. Les axes représentent l'Easting et le Northing en mètres.

9 Conclusion

Ce mini-projet a permis de comparer plusieurs niveaux de modélisation pour prédire la satisfaction hôtelière :

— Ce mini-projet a permis de comparer plusieurs niveaux de modélisation pour prédire la satisfaction hôtelière. Les modèles tabulaires basiques donnent des performances limitées, avec un R^2 maximal de 0.2586 pour Random Forest. L'ACP ne permet pas d'améliorer les résultats et dégrade même les performances, ce qui montre que les variables originales sont plus utiles que les composantes réduites pour ce problème.
— Le MLP tuné améliore légèrement les résultats tabulaires et devient le meilleur modèle sur la cible target_stage1_tabular_score, avec un R^2 de 0.3259. Cependant, la meilleure performance globale est obtenue par le modèle textuel TF-IDF + Ridge, avec un R^2 de 0.8350 sur la cible text_hotel_score.
— Cette différence s'explique par le changement de cible et de variables : le score textuel est directement lié au contenu des avis clients, alors que les variables tabulaires ne capturent qu'indirectement la satisfaction. Ainsi, le modèle textuel est le plus pertinent pour prédire une cible construite à partir du ressenti exprimé dans les avis.

En résumé, la modélisation textuelle avec un modèle de type BERT représente l'approche la plus prometteuse pour ce type de tâche, car les avis écrits contiennent une information sémantique riche que les variables tabulaires ne capturent pas.